



Segmentação de Vias Aéreas em Tomografias Computadorizadas.

Daniel Vaz Barbosa
Kauê Barbosa Oliveira
Madson Luan Dias Nascimento



Dataset Utilizado


AeroPath

- Dataset voltado para pesquisas em segmentação médica;
- Contém exames de tomografia computadorizada do tórax;
- Possui exames de 27 pacientes;
- Inclui máscaras para validação.


Tomografia (Fatia Axial Z=383)



Máscara: Vias Aéreas



Sobreposição (CT + Máscara)



Objetivo Principal

Isolar a árvore brônquica e vias aéreas em exames de forma autônoma, sem o uso de Deep Learning.





Contexto e Problema

1. Segmentação de vias aéreas pulmonares identifica automaticamente estruturas como traquéia e árvore brônquica em exames de tomografia computadorizada.
 2. Esse processo auxilia no diagnóstico e acompanhamento de doenças pulmonares.
1. As vias aéreas são estruturas tubulares preenchidas por ar, apresentando baixos valores na escala Hounsfield (HU).
 2. O principal desafio é diferenciar as vias aéreas do parênquima pulmonar e de tecidos vizinhos com densidade semelhante.




Objetivos Específicos

- Aplicar técnicas clássicas de processamento de imagens ;
- Assegurar a robustez do método mantendo distanciamento de Redes Neurais;
- Criar uma heurística de inicialização totalmente autônoma ;
- Entregar uma discussão crítica sobre os resultados;




Metodologia

- Aquisição: Leitura de volumes no formato NIfTI utilizando Python e biblioteca nibabel.
- Inicialização: Detecção automática da traqueia no eixo Z baseada em heurísticas de anatomia espacial.
- Segmentação: Aplicação do Crescimento de Regiões 3D a partir da semente inicial.
- Pós-processamento: Correção adaptativa utilizando Morfologia Matemática para conter vazamentos.



Exploração e Preparação dos Dados

- Os dados foram fatiados e explorados visualmente no eixo axial para validação anatômica;
- O espaço de busca foi restrito aos limites pulmonares para otimizar o processamento computacional;
- Isolamos pixels baseados em Unidades Hounsfield típicas do ar para mapear densidades;
- O algoritmo filtra os componentes conectados por tamanho e proximidade do centro anatômico;



Z = 651



Inicialização automática da Semente

Como a semente foi escolhida:


- Foi selecionada uma fatia do volume tomográfico;
- O algoritmo buscou o voxel com menor valor de HU;
- Esse ponto corresponde à maior concentração de ar.

Execução:


A função flood() foi utilizada com tolerância de:

70 HU


CT Original (Z=651)




Máscara



Crescimento de Regiões



Sobreposição: CT + Crescimento de Regiões




Vazamento da Segmentação

Durante o crescimento de regiões ocorreu vazamento para o parênquima pulmonar.


Motivos:

- Intensidades semelhantes ao ar;
- Ruídos da imagem;
- Pequenas falhas nas paredes brônquicas.


CT Original (Z=383)




Máscara (Ground Truth)



Crescimento de Regiões



Sobreposição: CT + RG (Z=383)





Pós-processamento


Técnicas Aplicadas:

- Erosão;
- Dilatação;
- Análise de componentes conectados.


Estratégia:

- Romper conexões indevidas;
- Remover regiões pulmonares;
- Recuperar espessura das vias aéreas.


CT Original (Z=383)




Sem Pós-Proc (Com Vazamento)



Com Pós-Proc (Pulmão Removido)



Ground Truth Ideal





Análises e Modelagem

- Realizamos a comparação direta entre o Crescimento de Regiões.
- Avaliamos a eficiência do fechamento e da erosão morfológica espacial para limpeza de ruídos.
- Avaliação quantitativa baseada na interseção volumétrica de voxels contra a Máscara.

Métrica de Similaridade Dice

$$Dice = \frac{2 \times |A \cap B|}{|A| + |B|}$$

Métrica Intersection over Union

$$IoU = \frac{|A \cap B|}{|A \cup B|}.$$



Resultados Principais

Paciente 1


Dice	0.8046
IoU	0.6731

Geral


Dice	0.6766 ± 0.3349
IoU	0.5888

Visualizações (Paciente 1 e 2)


1. Traqueia (Z=651)



2. Vazamento (Z=383)




3. Corrigido com ball(1)




4. Máscara Ideal



5. Zoom: Predição vs GT (Z=383)



1. Traqueia (Z=704)




2. Vazamento (Z=383)




3. Corrigido com ball(1)



4. Máscara Ideal




5. Zoom: Predição vs GT (Z=383)




Visualizações (Paciente 18)


1. Traqueia (Z=600)




2. Vazamento (Z=383)




3. Corrigido com ball(0)



4. Máscara Ideal



5. Zoom: Predição vs GT (Z=383)





Discussão de Erros

- Vazamento massivo (Leakage) foi o maior obstáculo enfrentado durante a propagação 3D.
- Variações Anatômicas e de Aquisição também foi um dos obstáculos enfrentados.
- A Morfologia Matemática provou-se crucial para quebrar a conexão indesejada entre vias aéreas e pulmão.



Conclusões

- Métodos clássicos resolvem o desafio de extração com excelência em casos sem forte variação anatômica.
- Limiares fixos de tolerância falham ao lidar com valores atípicos e ruídos severos de tomógrafos.
- Um pipeline clássico sem Deep Learning exige obrigatoriamente heurísticas robustas de pós-processamento.
- A construção do algoritmo revelou que a qualidade da análise física dos artefatos médicos supera o valor absoluto das métricas.



Melhorias

- Substituir os limiares fixos da semente por cálculos estatísticos adaptativos de densidade.
- Implementar o ajuste dinâmico de tolerância para os pacientes.
- Criar um loop inteligente que altere automaticamente o tamanho do elemento estruturante com base no volume do erro.
- Generalizar a varredura e encapsular os algoritmos para escalar o projeto a novas bases de dados.

Obrigado!

